

PROJECT UAS / BIG CHALLENGE
SINF1004 - STRUKTUR DATA DAN ALGORITMA
Program Studi Informatika
Fakultas Matematika Dan Ilmu Pengetahuan Alam
Universitas Syiah Kuala

Dosen Pengasuh
Prof. Dr. Taufik Fuadi Abidin, M.Tech

PENDAHULUAN

Big Challenge merupakan projek akhir setara ujian akhir yang diberikan kepada mahasiswa untuk diselesaikan dengan menggunakan konsep dan metode yang telah dipelajari pada mata kuliah **Struktur Data dan Algoritma**. Selain menyelesaikan permasalahan yang diberikan, mahasiswa juga harus menyiapkan video rekaman pemaparan yang menjelaskan bagaimana permasalahan diselesaikan. **Big Challenge** memiliki bobot setara **Ujian Akhir Semester (UAS)**. Setelah mengerjakan *big challenge* ini, mahasiswa diharapkan mampu:

1. Memahami konsep struktur data secara lebih baik dan memahami cara menyelesaikan masalah menjadi suatu bentuk solusi menggunakan bahasa pemrograman ANSI/C dan struktur data yang efisien.
2. Memahami cara mengurutkan data dalam jumlah besar menggunakan metode pengurutan **quicksort**, **heapsort**, dan salah satu dari metode pengurutan sederhana (i.e. **bubblesort**, **insertionsort**, atau **selectionsort**). Selain itu, mahasiswa diharapkan mampu menghitung total frekuensi dari *bag-of-words* dan menghitung waktu yang dibutuhkan oleh setiap metode dalam melakukan pengurutan.
3. Menampilkan keluaran ke layar monitor dan menyimpan hasil keluaran dalam file teks.

Big Challenge merupakan **tugas kelompok 2 (dua) orang mahasiswa**. Mahasiswa tidak dibenarkan memberikan hasil pekerjaannya kepada mahasiswa atau kelompok lain. Bila dalam penyelesaian tugas ini, ada fungsi atau program yang diambil dari sumber lain, maka sumber tersebut harus ditulis dan mahasiswa wajib memahami maksud dari fungsi dan sub bagian program yang dikutip tersebut.

PENGUMPULAN TUGAS

Tugas ini harus dikumpulkan paling lambat pada tanggal **25 Mei 2025, pukul 23.59 WIB** secara elektronik via sistem e-learning (<http://www.elearning.usk.ac.id/>). File yang diunggah harus berupa sebuah file terkompres (zip atau rar atau tar) yang didalamnya terdapat file-file tugas (*source code*) dan file laporan. File laporan memiliki cover yang menyertakan nama dan NPM mahasiswa dalam kelompok. Isi dari laporan adalah snapshot dan penjelasan bagaimana permasalahan diselesaikan dan penjelasan tambahan yang dianggap perlu untuk mendukung proses penilaian. Nama file yang dikumpulkan harus ditulis dalam format sebagai berikut:

nama_kelompok.zip atau nama_kelompok.rar atau nama_npm_nama_kelompok.tar.

PROBLEM

Dataset **Bag of Words** di <http://archive.ics.uci.edu/ml/datasets/Bag+of+Words> adalah salah satu dataset teks yang terdapat dalam **Machine Learning Repository**. Dataset ini didonasi oleh David Newman dari University of California, Irvine, USA. Dataset ini berasal dari beberapa sumber, secara detail dapat dilihat via URL berikut:

<http://archive.ics.uci.edu/ml/machine-learning-databases/bag-of-words/>

Dua data terbesar dalam dataset tersebut adalah `docword.nytimes.txt.gz` dan `docword.pubmed.txt.gz` yang masing-masing berukuran **223M** dan **1.7G**. Unduh kelima file `docword` tersebut.

Untuk setiap koleksi dalam file `docword.*.txt`, D adalah jumlah dokumen, W adalah jumlah kata yang ada dalam file vocabulary, dan N adalah jumlah total kata yang ada dalam koleksi. Ketiga nilai tersebut berada pada 3 baris pertama file. Selanjutnya, pada baris 4 dan seterusnya terdapat data NNZ yang merupakan nilai frekuensi dari kata dalam dokumen. **Kata** yang terdapat dalam file vocabulary (`vocab.*.txt`) terkait erat dengan nilai **kolom kedua (wordID)** dari data NNZ pada file `docword.*.txt`. Sebagai ilustrasi, file `docword.kos.txt` terkait erat dengan file `vocab.kos.txt`, dan file `docword.nytimes.txt` terkait erat dengan file `vocab.nytimes.txt`. Jadi setiap 1 file `docword.*.txt` terkait dengan 1 file vocabulary `vocab.*.txt`.

Kelima file `docword.*.txt` adalah:

Enron Emails:
orig source: `www.cs.cmu.edu/~enron`
 $D=39861$
 $W=28102$
 $N=6,400,000$ (approx)

NIPS full papers:
orig source: `books.nips.cc`
 $D=1500$
 $W=12419$
 $N=1,900,000$ (approx)

KOS blog entries:
orig source: `dailykos.com`
 $D=3430$
 $W=6906$
 $N=467714$

NYTimes news articles:
orig source: `ldc.upenn.edu`
 $D=300000$
 $W=102660$
 $N=100,000,000$ (approx)

PubMed abstracts:
orig source: `www.pubmed.gov`
 $D=8200000$
 $W=141043$
 $N=730,000,000$ (approx)

Format dari file docword.*.txt adalah D , W , N yang diikuti dengan triple NNZ.

```
D
W
N
docID wordID count
docID wordID count
...
docID wordID count
docID wordID count
```

Contoh:

```
3430
6906
353160
1 61 2
1 76 1
2 61 5
2 89 3
:
```

Nilai 3430 menyatakan jumlah dokumen dalam koleksi. Nilai 6906 menyatakan jumlah unik kata dalam file vocabulary, dan nilai 353160 menyatakan jumlah baris triple NNZ dalam file yang menyatakan jumlah frekuensi kemunculan kata dalam dokumen. Informasi NNZ: 1 61 2 menyatakan bahwa frekuensi kata ke-61 (kata pada baris ke-61 dalam file vocabulary) adalah 2 dalam dokumen 1 dan informasi NNZ: 2 61 5 menyatakan bahwa frekuensi kata ke-61 adalah 5 dalam dokumen 2. Kedua frekuensi dari kata ke-61 tersebut harus dijumlahkan.

Anda dimintakan untuk menentukan struktur data terbaik agar dapat menentukan k kata yang paling sering muncul dalam koleksi ($10 < k < 150$). Untuk menentukan kata-kata tersebut, dalam **Big Challenge** ini anda harus menghitung total frekuensi sebuah kata (yang mungkin muncul dalam beberapa dokumen docID), mengurutkannya dalam urutan besar ke kecil. Kemudian, k kata dengan nilai terbesar disimpan dalam file dan ditampilkan di layar monitor. Anda juga diminta untuk mengurutkan data tersebut menggunakan metode quick sort, heapsort, dan **salah satu** metode pengurutan sederhana yaitu **bubblesort, selection sort, atau insertion sort**. Jumlah waktu yang dibutuhkan untuk menentukan k kata yang paling sering muncul (dengan mengurutkannya) harus ditampilkan di layar monitor dan dalam file output. Program yang dibuat harus menyediakan fungsionalitas minimal sebagai berikut:

Tentukan file docword: (menunggu masukkan dari user)

```
/***** Petunjuk *****/
```

Langkah-langkah yang harus dilakukan selanjutnya adalah:

1. Buka file docword dan vocabulary.
2. Baca data baris per baris dan tempatkan dalam struktur data tertentu.
3. Selanjutnya, MENU pilihan ditampilkan dan pilihan ditentukan oleh user. Proses dilanjutkan berdasarkan pilihan user.

```
*****/
```

Pilihan:

- 1) Urutkan data menggunakan salah satu metode pengurutan sederhana. Simpan keluaran dalam sebuah file teks secara descending order, termasuk waktu yang dibutuhkan untuk mengurutkan data tersebut.

Contoh format keluaran:

```
programming (201)
big (180)
challenge (178)
:
```

Waktu untuk mengurutkan: 564 ms

- 2) Urutkan data menggunakan metode quicksort. Simpan keluaran dalam sebuah file teks secara descending order dan tampilkan waktu yang dibutuhkan untuk mengurutkan data tsb.
- 3) Urutkan data menggunakan metode heapsort. Simpan keluaran dalam sebuah file teks secara descending order dan tampilkan waktu yang dibutuhkan untuk mengurutkan data tsb.
- 4) Tampilkan ke layar monitor 100 kata dengan frekuensi terbesar termasuk waktu yang dibutuhkan untuk mengurutkan data tsb.
- 5) Selesai

Pilihan anda: _

Bila **pilihan (1)** dipilih maka program akan mengurutkan data menggunakan metode **pengurutan sederhana** (bubble sort, insertion sort atau selection sort) dan menyimpan keluaran dalam format sesuai contoh di atasurut secara *descending* ke dalam sebuah file teks. Penentuan nama file output boleh dilakukan secara manual atau secara dinamis.

Bila **pilihan (2)** dipilih maka program akan mengurutkan data menggunakan metode **quicksort** dan menyimpan keluaran dalam format sesuai contoh di atasurut secara *descending* ke dalam sebuah file teks. Penentuan nama file output boleh dilakukan secara manual atau secara dinamis.

Bila **pilihan (3)** dipilih maka program akan mengurutkan data menggunakan metode **heapsort** dan menyimpan keluaran dalam format sesuai contoh di atasurut secara *descending* ke dalam sebuah file teks. Penentuan nama file output boleh dilakukan secara manual atau secara dinamis.

Bila **pilihan (4)** dipilih maka program akan mencetak hasil ke layar monitor berupa kata dan frekuensinya sebanyak maksimum **k kata** dalam format sesuai contoh di atasurut berdasarkan frekuensi secara *descending*. Nilai **k** ditentukan ketika pilihan 4 dipilih. Jumlah waktu untuk mengurutkan juga harus ditampilkan.

Bila **pilihan (5)** yang dipilih maka program akan berakhir.

Catatan:

Untuk mendapat nilai penuh, program big challenge harus dapat menangani semua file docword.*.txt yang ada dalam UCI repository yang telah diurai sebelumnya.